Министерство науки и высшего образования Российской Федерации
РГУ нефти и газа (НИУ) имени И.М. Губкина

Кафедра безопасности информационных технологий

Протокол воспроизведения эксперимента
к научной статье по дисциплине
«Современные операционные системы»

Выполнили
студенты группы КВ-24-07
Гольцман М.Э.
Гаевский Р.А.
Проверил
преподаватель каф. БИТ
Павловский В.В.

Москва 2026

Протокол воспроизведения эксперимента

«Влияние расписания задания оптимизации дедупликации на объем неоптимизированных данных»

Гольцман М.Э., Гаевский Р.А.

РГУ нефти и газа (НИУ) имени И.М. Губкина, кафедра БИТ, группа КВ-24-07

1. Назначение и состав материалов

Протокол описывает порядок развертывания стенда, проведения серий и обработки результатов эксперимента SOS-013 / WIN-061, а также фактические условия, в которых получены данные, приведенные в статье. Выполнение пунктов 4.1–4.7 на оборудовании с аналогичными характеристиками позволяет повторить эксперимент и получить сопоставимые результаты.

Материалы работы:

1) статья «Влияние расписания задания оптимизации дедупликации на объем неоптимизированных данных» (папка 1_Отчет) – отчет с таблицами и графиками экономии пространства и времени;

2) скрипты настройки заданий и измерения (папка 2_Скрипты), их назначение приведено в таблице 1;

3) настоящий протокол воспроизведения (папка 3_Протокол).

Таблица 1 – Скрипты эксперимента

Файл	Где выполняется	Назначение
01-Host-CreateVM.ps1	хост	Создание ВМ Hyper-V 2-го поколения с тремя виртуальными дисками и подключенным образом ISO
02-Host-DeployToVM.ps1	хост	Подготовка стенда внутри ВМ через PowerShell Direct, создание исходного набора данных и контрольной точки Base
03-Host-RunAll.ps1	хост	Проведение серий в случайном порядке с откатом к Base перед каждой серией, копирование и объединение результатов
Dedup-ScheduleExperiment.ps1	ВМ (итоговая сводка – на хосте)	Настройка дедупликации и расписаний, генерация притока данных, запуск задания оптимизации, замеры, резервное копирование Windows Server Backup
analyze_results.py	хост, Python 3	Статистическая обработка: медиана, IQR, CV, U-критерий Манна – Уитни, сводная таблица, рисунки, анализ чувствительности и проверка метрики

2. Требования к стенду

Требования к хосту:

1) Windows 10/11 (Pro, Enterprise или Education) или Windows Server с включенным компонентом Hyper-V, процессор с поддержкой аппаратной виртуализации;

2) не менее 8 ГБ свободной оперативной памяти для ВМ (при нехватке допускается 4 ГБ, см. п. 4.6);

3) диск F: с файловой системой NTFS и не менее 300 ГБ свободного места; диски ВМ динамические, перед каждой серией (после отката к Base) скрипт проверяет, что свободно не меньше 180 ГБ;

4) образ Windows Server 2025 (ознакомительная версия Datacenter Evaluation), сохраненный как F:\ISO\WS2025.iso;

5) Windows PowerShell 5.1 с модулем Hyper-V, запущенный от имени администратора;

6) Python 3.10 или новее с пакетами numpy и matplotlib для обработки результатов.

Конфигурация виртуальной машины, которую создает скрипт 01-Host-CreateVM.ps1, приведена в таблице 2.

Таблица 2 – Конфигурация виртуальной машины

Параметр	Значение
Имя, поколение	WS2025-DEDUP, 2-е поколение
Процессор, память	4 vCPU; 8 ГБ ОЗУ, статическая память
Диск os.vhdx	80 ГБ, системный том C:
Диск data.vhdx	200 ГБ, том E: (метка DATA, NTFS, кластер 4 КБ), дедупликация включена
Диск backup.vhdx	300 ГБ, том G: (метка BACKUP) для копий Windows Server Backup
Размещение	F:\HyperV\WS2025-DEDUP, динамические диски VHDX
Контрольные точки	рабочие (Production), автоматические контрольные точки отключены
Сеть	адаптер подключается к коммутатору Default Switch, если он есть; для эксперимента сеть не нужна, управление через PowerShell Direct

3. Параметры эксперимента

Значения параметров и место, где они задаются, приведены в таблице 3. По умолчанию скрипты используют значения, с которыми проводился эксперимент.

Таблица 3 – Параметры эксперимента

Параметр	Значение	Где задается
Периодичность задания оптимизации	ежедневно в 02:00 (Daily); еженедельно, воскресенье 02:00 (Weekly)	03-Host-RunAll.ps1 -Schedules

Параметр	Значение	Где задается
Интенсивность притока	2 и 6 ГБ/сут	03-Host-RunAll.ps1 -Intensities
Разброс суточного притока	12 %, нормальное распределение	гостевой скрипт -IntensityCV
Повторяющиеся блоки в новых данных	50 %, пул из 64 блоков по 1 МиБ	гостевой скрипт -DuplicateShare
Приток в течение суток	08:00–20:00, 12 порций	гостевой скрипт
Длительность серии	14 сут (2 недельных цикла)	03-Host-RunAll.ps1 -Days
Повторы	5 по плану, выполнено 4 (раздел 5)	03-Host-RunAll.ps1 -Repeats
Исходный набор	40 ГБ, оптимизирован до создания контрольной точки Base	02-Host-DeployToVM.ps1 -SeedGB
Настройки тома E:	тип Default, MinimumFileAgeDays = 0, стандартные расписания отключены	гостевой скрипт -Action Prepare
Резервное копирование	полная копия тома E: на том G: (wbadmin) раз в неделю, в 23:00 6-х и 13-х суток	гостевой скрипт
Зависимая переменная	суммарный размер файлов не меньше 32 КБ без атрибута ReparsePoint в E:\Data непосредственно перед запуском задания	гостевой скрипт, функция Measure-Fast

Серии выполняются в ускоренном режиме: модельные сутки следуют подряд без ожидания реального времени, а задание оптимизации запускается командой Start-DedupJob -Type Optimization -Wait в момент, соответствующий расписанию: при ежедневном – в 02:00 2–15-х суток, при еженедельном – в 02:00 8-х и 15-х суток, то есть после каждых 7 суток притока, с тем же интервалом, что и при запуске по воскресеньям. Поскольку MinimumFileAgeDays = 0, результат задания определяется объемом накопленных данных, а не календарным временем. Настройка настоящего расписания через New-DedupSchedule описана в приложении Б.

4. Порядок проведения

Команды на хосте выполняются в Windows PowerShell, запущенном от имени администратора, в папке со скриптами F:\SOS-013\scripts.

4.1 Подготовка хоста

1) Включить Hyper-V и перезагрузить компьютер:

```
Enable-WindowsOptionalFeature -Online -FeatureName Microsoft-Hyper-V -All
```

2) Скопировать скрипты в папку F:\SOS-013\scripts, образ – в F:\ISO\WS2025.iso.

3) Разрешить выполнение скриптов в текущем сеансе и снять с файлов отметку загрузки из интернета:

```
cd F:\SOS-013\scripts
Set-ExecutionPolicy -Scope Process Bypass -Force
Get-ChildItem . | Unblock-File
```

4) На время прогона отключить переход компьютера в спящий режим:

```
powercfg /change standby-timeout-ac 0
```

Ожидаемый результат. Команда Get-VMHost выполняется без ошибок, Get-PSDrive F показывает не менее 300 ГБ свободного места.

4.2 Создание виртуальной машины

```
.\01-Host-CreateVM.ps1 -IsoPath 'F:\ISO\WS2025.iso'
```

Если ВМ с таким именем уже существует, скрипт останавливается с сообщением; для пересоздания указывается ключ -Replace (старая ВМ и ее диски удаляются).

Ожидаемый результат. Создана ВМ WS2025-DEDUP с дисками os.vhdx, data.vhdx и backup.vhdx в папке F:\HyperV\WS2025-DEDUP, ВМ запущена, открыто окно подключения.

4.3 Установка Windows Server 2025

1) В окне подключения сразу после запуска нажать любую клавишу, чтобы загрузиться с DVD. Если загрузка с DVD не началась, выключить ВМ (Stop-VM WS2025-DEDUP -TurnOff), запустить ее снова (Start-VM WS2025-DEDUP) и сразу нажать клавишу.

2) Выбрать редакцию Windows Server 2025 Datacenter Evaluation (с возможностями рабочего стола) и установить систему на диск 0 (80 ГБ). Диски 1 и 2 не размечать, это делает скрипт на следующем шаге.

3) Задать пароль встроенной учетной записи администратора; его удобнее набирать в английской раскладке. Имя и пароль этой учетной записи используются для подключения к ВМ через PowerShell Direct. В русской редакции Windows Server учетная запись называется «Администратор»; чтобы команды протокола выполнялись без изменений, ее можно переименовать в PowerShell внутри ВМ:

```
Rename-LocalUser -Name 'Администратор' -NewName 'Administrator'
```

Если учетная запись не переименована, в командах вместо Administrator указывается Администратор.

Ожидаемый результат. Вход в систему выполняется, на рабочем столе указаны редакция Windows Server 2025 Datacenter Evaluation и сборка 26100 (рисунок 2 статьи).

4.4 Подготовка стенда и контрольная точка Base

```
$c = Get-Credential Administrator
.\02-Host-DeployToVM.ps1 -Credential $c
```

Скрипт отключает образ ISO, копирует гостевой скрипт в C:\DedupExp, устанавливает компоненты FS-Data-Deduplication и Windows-Server-Backup, размечает тома E: (DATA) и G: (BACKUP), включает дедупликацию на томе E:, задает MinimumFileAgeDays = 0 и отключает все стандартные расписания дедупликации. Затем создается и оптимизируется исходный набор 40 ГБ, ВМ выключается и создается контрольная точка Base. Длительность шага определяется в основном записью и оптимизацией исходного набора.

Ожидаемый результат. Создан файл results\stand_status.txt: дедупликация тома E: включена, MinimumFileAgeDays = 0, у всех расписаний Enabled = False, на исходном наборе 40 ГБ сэкономлено около 18,7 ГБ (рисунки 3–5 статьи). Команда Get-VMSnapshot WS2025-DEDUP показывает контрольную точку Base.

4.5 Пробный прогон

```
.\03-Host-RunAll.ps1 -Credential $c -Smoke
```

Выполняется одна короткая серия (еженедельное расписание, 0,5 ГБ/сут, 7 сут, без копий WSB) с откатом к Base, примерно 10–15 мин. Пробный прогон проверяет откат, связь с ВМ, работу задачи планировщика и копирование результатов на хост; его данные в обработку не включаются.

Ожидаемый результат. В папке results_smoke\Weekly_0.5GB_r1 находятся runs.csv (одна строка, объем перед запуском около 3,5 ГБ), events.csv, meta.json, progress.log и done.txt, в конце выводится сводная таблица.

4.6 Основной прогон

```
.\03-Host-RunAll.ps1 -Credential $c -Repeats 4
```

Выполняются 16 серий (2 расписания × 2 интенсивности × 4 повтора) в случайном порядке с фиксированным зерном 2026; без параметра -Repeats план составляет 20 серий (n = 5). Каждая серия начинается с отката к Base и выполняется внутри ВМ как задача планировщика от имени SYSTEM, хост раз в минуту выводит последнюю строку журнала серии. Результаты копируются в папку results\<расписание>_<приток>GB_r<повтор> до следующего отката.

Прогон можно прервать (Ctrl+C) и запустить той же командой снова: серии с файлом done.txt пропускаются, незавершенная серия выполняется заново от контрольной точки Base. Если на хосте не хватает памяти для ВМ с 8 ГБ ОЗУ, к команде добавляется ключ -MemoryGB 4; объем памяти задается после каждого отката.

Ожидаемый результат. Папки всех серий содержат done.txt; в папке results созданы объединенные файлы runs.csv, events.csv и wsb.csv, в конце выводится сводная таблица. При ежедневном расписании объем перед запуском близок к суточному притоку (около 2 и 6 ГБ), при еженедельном – к недельному (около 14 и 42 ГБ).

Для расширенного плана (n = 8) используется ключ -Repeats 8, для контрольных серий без резервного копирования ключ -NoBackup (результаты сохраняются в отдельную папку results_noWSB). Начиная с этой версии гостевой скрипт перед каждым заданием дополнительно записывает показатели Get-DedupStatus (столбцы StatusInPolicyGB, StatusOptimizedGB, StatusUnoptGB) для сравнения с основной метрикой.

4.7 Обработка результатов

```
pip install numpy matplotlib
python analyze_results.py --results results
```

Ожидаемый результат. В папке results\analysis созданы summary.csv (сводная таблица по всем показателям, таблицы 3 и 5 статьи), summary.txt (то же в текстовом виде с результатами U-критерия), stats.txt (стратифицированный перестановочный тест, поправка Холма, величина эффекта, доверительные интервалы Ходжеса-Лемана, мощность, анализ без серий с 4 ГБ ОЗУ, проверка метрики и влияния WSB; таблица 4 статьи) и рисунки fig6_dynamics.png, fig7_prejob.png, fig8_jobtime.png (рисунки 6–8 статьи). Критерий завершения выполнен, если в каждой группе CV < 15 %, а медианы при ежедневном и еженедельном расписании различаются не менее чем на 10 %.

5. Фактические условия проведения

Эксперимент проведен на ВМ Windows Server 2025 Datacenter Evaluation (сборка 26100), размещенной на диске F: хоста. Стенд подготовлен 26.09.2026, серии выполнены с 27.09 по 03.10.2026, суммарное машинное время прогона составило 139 ч. Прогон несколько раз прерывался (ошибки подключения к ВМ, нехватка места на диске и оперативной памяти хоста) и продолжался повторным запуском 03-Host-RunAll.ps1; прерванные серии выполнялись заново от контрольной точки Base.

Отклонения от плана:

1) Из-за длительности прогона выполнено 16 серий из 20 запланированных, по 4 повтора на каждую комбинацию факторов. Прогон начат по плану из 20 серий и остановлен после 13-й серии; недостающие повторы для ежедневного расписания (Daily_2GB_r3, Daily_2GB_r4, Daily_6GB_r2) выполнены отдельными запусками 03-Host-RunAll.ps1 с планом, ограниченным параметрами -Schedules, -Intensities и -Repeats (готовые серии при этом пропускаются), например:

```
.\03-Host-RunAll.ps1 -Credential $c -Schedules Daily -Intensities 2 `
    -Repeats 4 -MemoryGB 4
```

Поэтому номера повторов в комбинациях не совпадают (таблица 4). На результат это не влияет: все серии начинаются с одной контрольной точки, а порядок серий случайный.

2) Серии Daily_2GB_r3, Daily_2GB_r4 и Daily_6GB_r2 выполнены с 4 ГБ ОЗУ ВМ (ключ -MemoryGB 4) из-за нехватки памяти на хосте. На объем неоптимизированных данных это не влияет, но могло увеличить разброс длительности заданий оптимизации.

Таблица 4 – Выполненные серии

Комбинация	**Серии**	**ОЗУ ВМ**
2 ГБ/сут, ежедневно	Daily_2GB_r1, r2, r3, r4	r1, r2 – 8 ГБ; r3, r4 – 4 ГБ
2 ГБ/сут, еженедельно	Weekly_2GB_r2, r3, r4, r5	8 ГБ
6 ГБ/сут, ежедневно	Daily_6GB_r1, r2, r4, r5	r2 – 4 ГБ; остальные – 8 ГБ
6 ГБ/сут, еженедельно	Weekly_6GB_r1, r2, r3, r4	8 ГБ

Основные результаты приведены в таблице 5, полностью – в таблицах 3–5 статьи.

Таблица 5 – Средний объем неоптимизированных данных перед запуском задания, ГБ (n = 4)

Приток	**Ежедневно: медиана [IQR]**	**Еженедельно: медиана [IQR]**	**CV, % (ежедн. / еженед.)**	**U; p (по Холму)**
2 ГБ/сут	1,97 [0,03]	14,31 [0,59]	2,6 / 4,0	0; 0,029 (0,057)
6 ГБ/сут	5,98 [0,26]	42,00 [0,77]	3,3 / 2,3	0; 0,029 (0,057)

Переход к еженедельному расписанию увеличил медиану в 7,25 раза при 2 ГБ/сут и в 7,02 раза при 6 ГБ/сут. Коэффициент вариации во всех группах не превышает 4,0 %, критерий завершения выполнен. Основная проверка (стратифицированный перестановочный тест по обеим интенсивностям) дает p = 0,0004; без серий с 4 ГБ ОЗУ p = 0,004. Отдельные сравнения после поправки Холма при n = 4 не значимы, поэтому выводы предварительные.

6. Формат файлов результатов

CSV-файлы записываются в кодировке UTF-8, разделитель полей – точка с запятой, десятичный разделитель – точка. Day – номер модельных суток от начала серии; задание в сутки Day выполняется в 02:00, до притока этих суток. Состав файлов в папке каждой серии приведен в таблице 6.

Таблица 6 – Файлы результатов серии

Файл	Содержимое
runs.csv	Строка на каждый запуск задания: Schedule, IntensityGB, Repeat, Run, Day, Timestamp, UnoptimizedGB (объем перед запуском), LogicalGB, JobMinutes, ResidualGB (остаток после задания), SavedGB, JobResult
events.csv	Состояние тома по модельным часам: Schedule, IntensityGB, Repeat, Day, Hour, Event (start, intake, job), UnoptimizedGB, LogicalGB, SavedGB
wsb.csv	Полные копии WSB: Schedule, IntensityGB, Repeat, Day, UsedGB, ImageGB, Minutes, ExitCode
meta.json	Параметры серии и стенда: ОС и сборка, vCPU, RamGB, размер тома, UsageType, MinimumFileAgeDays, объем и экономия исходного набора, время начала
progress.log	Журнал выполнения серии
done.txt, failed.txt	Признак успешного завершения серии или ошибки (в failed.txt записан текст ошибки)

Кроме папок серий, в каталоге results находятся stand_status.txt (сведения о стенде после подготовки), plan_order.csv (порядок серий последнего запуска) и объединенные runs.csv, events.csv, wsb.csv.

7. Возможные неполадки

Таблица 7 – Возможные неполадки и их устранение

Признак	Причина и действие
«ВМ WS2025-DEDUP уже существует» при запуске 01-Host-CreateVM.ps1	ВМ осталась от прошлой попытки. Запустить скрипт с ключом -Replace.
ВМ не загружается с DVD, выполняется попытка загрузки по сети	Клавиша не нажата вовремя. Выключить ВМ, запустить снова и сразу нажать любую клавишу в окне подключения.
«Недопустимые учетные данные» при подключении к ВМ	Неверное имя или пароль. Проверить имя учетной записи (Administrator или Администратор, п. 4.3) и раскладку клавиатуры при вводе пароля. Сразу после загрузки ВМ ошибка может появляться временно, скрипты ожидают до 4 мин.
«Не удалось выделить … МБ ОЗУ» при запуске ВМ	На хосте недостаточно свободной памяти. Закрыть лишние программы или запустить 03-Host-RunAll.ps1 с ключом -MemoryGB 4.
«На диске F: свободно … ГБ, для серии нужно не меньше 180 ГБ» или ВМ в состоянии «Приостановлена»	На диске хоста не хватает места. Освободить место на диске F:. В первом случае запустить скрипт снова (готовые серии будут пропущены), во втором – выполнить Resume-VM WS2025-DEDUP, скрипт продолжит ожидание серии.
Серия завершилась с ошибкой (создан failed.txt)	Причина указана в progress.log и failed.txt в папке серии. После ее устранения запустить 03-Host-RunAll.ps1 снова.

Приложение А

Ручная проверка настроек и измерения

Проверка выполняется внутри ВМ в окне подключения или в сеансе Enter-PSSession -VMName WS2025-DEDUP -Credential $c:

```
Get-DedupVolume -Volume E: |
    Format-List Volume, Enabled, UsageType, MinimumFileAgeDays
Get-DedupSchedule | Format-Table Name, Type, Enabled
Update-DedupStatus -Volume E:
Get-DedupStatus -Volume E: |
    Format-List OptimizedFilesCount, InPolicyFilesCount, SavedSpace

# объем неоптимизированных данных (так же считает Measure-Fast)
$u = Get-ChildItem E:\Data -Recurse -File |
  Where-Object { $_.Length -ge 32KB -and
    -not ($_.Attributes -band [IO.FileAttributes]::ReparsePoint) } |
  Measure-Object Length -Sum
'{0:N2} ГБ' -f ($u.Sum / 1GB)

# у оптимизированного файла есть точка повторного анализа
fsutil reparsepoint query E:\Data\base\f00000.bin
```

После запуска задания оптимизации (Start-DedupJob -Volume E: -Type Optimization -Wait) значение $u уменьшается практически до нуля, а fsutil для оптимизированных файлов показывает тег точки повторного анализа дедупликации 0x80000013. Файлы меньше 32 КБ не оптимизируются и в расчет не входят.

Приложение Б

Режим реального времени

Для проверки на настоящем расписании гостевой скрипт создает задание дедупликации через New-DedupSchedule и задачи планировщика. Команды выполняются внутри ВМ после отката к контрольной точке Base:

```
cd C:\DedupExp
.\Dedup-ScheduleExperiment.ps1 -Action RealTimeSetup `
    -Schedule Weekly -IntensityGB 2
```

Создаются расписание дедупликации Exp-Weekly (воскресенье 02:00, не более 6 ч; при -Schedule Daily – ежедневно в 02:00) и задачи планировщика:

1) DedupExp-Intake – приток каждый час с 08:00 до 19:00 (12 порций в сутки);

2) DedupExp-Measure – замер объема в 01:55, перед запуском задания, с записью в runs.csv;

3) DedupExp-Backup – полная копия тома E: средствами WSB в субботу в 23:00.

Результаты записываются в C:\DedupExp\out. Два недельных цикла в этом режиме занимают 14 календарных суток на одну серию, поэтому результаты статьи получены в ускоренном режиме. Удаление расписания и задач:

```
Get-ScheduledTask -TaskName 'DedupExp-*' |
    Unregister-ScheduledTask -Confirm:$false
Remove-DedupSchedule -Name 'Exp-Weekly'
```