Министерство науки и высшего образования Российской Федерации
РГУ нефти и газа (НИУ) имени И.М. Губкина

Кафедра безопасности информационных технологий

Протокол воспроизведения эксперимента к научной статье по дисциплине «Современные операционные системы»

Выполнили
студенты группы КВ-24-07
Гольцман М.Э.
Гаевский Р.А.
Проверил
ст. преподаватель каф. БИТ
Уймин А.Г.

Москва 2026

Протокол воспроизведения эксперимента

«Влияние расписания задания оптимизации дедупликации на объем неоптимизированных данных»

Гольцман М.Э., Гаевский Р.А.

РГУ нефти и газа (НИУ) имени И.М. Губкина, кафедра БИТ, группа КВ-24-07

1. Назначение и состав материалов

Протокол описывает порядок развертывания стенда, проведения серий и обработки результатов эксперимента SOS-013 / WIN-061, а также фактические условия, в которых получены данные, приведенные в статье. Выполнение пунктов 4.1–4.7 на оборудовании с аналогичными характеристиками позволяет повторить эксперимент и получить сопоставимые результаты.

Материалы работы:

1) статья «Влияние расписания задания оптимизации дедупликации на объем неоптимизированных данных» (папка 1_Отчет) – отчет с таблицами и графиками экономии пространства и времени;

2) скрипты настройки заданий и измерения (папка 2_Скрипты), их назначение приведено в таблице 1;

3) настоящий протокол воспроизведения (папка 3_Протокол).

Таблица 1 – Скрипты эксперимента

Файл	Где выполняется	Назначение
01-Host-CreateVM.ps1	хост	Создание ВМ Hyper-V 2-го поколения с тремя виртуальными дисками и подключенным образом ISO
02-Host-DeployToVM.ps1	хост	Подготовка стенда внутри ВМ через PowerShell Direct, создание исходного набора данных и контрольной точки Base
03-Host-RunAll.ps1	хост	Проведение серий в случайном порядке с откатом к Base перед каждой серией, копирование и объединение результатов
Dedup-ScheduleExperiment.ps1	ВМ (итоговая сводка – на хосте)	Настройка дедупликации и расписаний, генерация притока данных, запуск задания оптимизации, замеры, резервное копирование Windows Server Backup
analyze_results.py	хост, Python 3	Статистическая обработка: медиана, IQR, CV, U-критерий Манна – Уитни, сводная таблица, рисунки, анализ чувствительности и проверка метрики

2. Требования к стенду

Требования к хосту:

1) Windows 10/11 (Pro, Enterprise или Education) или Windows Server с включенным компонентом Hyper-V, процессор с поддержкой аппаратной виртуализации;

2) не менее 8 ГБ свободной оперативной памяти для ВМ (при нехватке допускается 4 ГБ, см. п. 4.6);

3) диск F: с файловой системой NTFS и не менее 300 ГБ свободного места; диски ВМ динамические, перед каждой серией (после отката к Base) скрипт проверяет, что свободно не меньше 180 ГБ;

4) образ Windows Server 2025 (ознакомительная версия Datacenter Evaluation), сохраненный как F:\ISO\WS2025.iso;

5) Windows PowerShell 5.1 с модулем Hyper-V, запущенный от имени администратора;

6) Python 3.10 или новее с пакетами numpy и matplotlib для обработки результатов.

Конфигурация виртуальной машины, которую создает скрипт 01-Host-CreateVM.ps1, приведена в таблице 2.

Таблица 2 – Конфигурация виртуальной машины

Параметр	Значение
Имя, поколение	WS2025-DEDUP, 2-е поколение
Процессор, память	4 vCPU; 8 ГБ ОЗУ, статическая память
Диск os.vhdx	80 ГБ, системный том C:
Диск data.vhdx	200 ГБ, том E: (метка DATA, NTFS, кластер 4 КБ), дедупликация включена
Диск backup.vhdx	300 ГБ, том G: (метка BACKUP) для копий Windows Server Backup
Размещение	F:\HyperV\WS2025-DEDUP, динамические диски VHDX
Контрольные точки	рабочие (Production), автоматические контрольные точки отключены
Сеть	адаптер подключается к коммутатору Default Switch, если он есть; для эксперимента сеть не нужна, управление через PowerShell Direct

3. Параметры эксперимента

Значения параметров и место, где они задаются, приведены в таблице 3. По умолчанию скрипты используют значения, с которыми проводился эксперимент.

Таблица 3 – Параметры эксперимента

Параметр	Значение	Где задается
Периодичность задания оптимизации	ежедневно в 02:00 (Daily); еженедельно, воскресенье 02:00 (Weekly)	03-Host-RunAll.ps1 -Schedules

Параметр	Значение	Где задается
Интенсивность притока	2 и 6 ГБ/сут	03-Host-RunAll.ps1 -Intensities
Разброс суточного притока	12 %, нормальное распределение	гостевой скрипт -IntensityCV
Повторяющиеся блоки в новых данных	50 %, пул из 64 блоков по 1 МиБ	гостевой скрипт -DuplicateShare
Приток в течение суток	08:00–20:00, 12 порций	гостевой скрипт
Длительность серии	14 сут (2 недельных цикла)	03-Host-RunAll.ps1 -Days
Повторы	5 по плану, выполнено 4 (раздел 5)	03-Host-RunAll.ps1 -Repeats
Исходный набор	40 ГБ, оптимизирован до создания контрольной точки Base	02-Host-DeployToVM.ps1 -SeedGB
Настройки тома E:	тип Default, MinimumFileAgeDays = 0, стандартные расписания отключены	гостевой скрипт -Action Prepare
Резервное копирование	полная копия тома E: на том G: (wbadmin) раз в неделю, в 23:00 6-х и 13-х суток	гостевой скрипт
Зависимая переменная	суммарный размер файлов не меньше 32 КБ без атрибута ReparsePoint в E:\Data непосредственно перед запуском задания	гостевой скрипт, функция Measure-Fast

Серии выполняются в ускоренном режиме: модельные сутки следуют подряд без ожидания реального времени, а задание оптимизации запускается командой Start-DedupJob -Type Optimization -Wait в момент, соответствующий расписанию: при ежедневном – в 02:00 2–15-х суток, при еженедельном – в 02:00 8-х и 15-х суток, то есть после каждых 7 суток притока, с тем же интервалом, что и при запуске по воскресеньям. Поскольку MinimumFileAgeDays = 0, результат задания определяется объемом накопленных данных, а не календарным временем. Настройка настоящего расписания через New-DedupSchedule описана в приложении Б.

4. Порядок проведения

Команды на хосте выполняются в Windows PowerShell, запущенном от имени администратора, в папке со скриптами F:\SOS-013\scripts.

4.1 Подготовка хоста

1) Включить Hyper-V и перезагрузить компьютер:

```
Enable-WindowsOptionalFeature -Online -FeatureName Microsoft-Hyper-V -All
```

2) Скопировать скрипты в папку F:\SOS-013\scripts, образ – в F:\ISO\WS2025.iso.

3) Разрешить выполнение скриптов в текущем сеансе и снять с файлов отметку загрузки из интернета:

```
cd F:\SOS-013\scripts
Set-ExecutionPolicy -Scope Process Bypass -Force
Get-ChildItem . | Unblock-File
```

4) На время прогона отключить переход компьютера в спящий режим:

```
powercfg /change standby-timeout-ac 0
```

Ожидаемый результат. Команда Get-VMHost выполняется без ошибок, Get-PSDrive F показывает не менее 300 ГБ свободного места.

4.2 Создание виртуальной машины

```
.\01-Host-CreateVM.ps1 -IsoPath 'F:\ISO\WS2025.iso'
```

Если ВМ с таким именем уже существует, скрипт останавливается с сообщением; для пересоздания указывается ключ -Replace (старая ВМ и ее диски удаляются).

Ожидаемый результат. Создана ВМ WS2025-DEDUP с дисками os.vhdx, data.vhdx и backup.vhdx в папке F:\HyperV\WS2025-DEDUP, ВМ запущена, открыто окно подключения.

4.3 Установка Windows Server 2025

1) В окне подключения сразу после запуска нажать любую клавишу, чтобы загрузиться с DVD. Если загрузка с DVD не началась, выключить ВМ (Stop-VM WS2025-DEDUP -TurnOff), запустить ее снова (Start-VM WS2025-DEDUP) и сразу нажать клавишу.

2) Выбрать редакцию Windows Server 2025 Datacenter Evaluation (с возможностями рабочего стола) и установить систему на диск 0 (80 ГБ). Диски 1 и 2 не размечать, это делает скрипт на следующем шаге.

3) Задать пароль встроенной учетной записи администратора; его удобнее набирать в английской раскладке. Имя и пароль этой учетной записи используются для подключения к ВМ через PowerShell Direct. В русской редакции Windows Server учетная запись называется «Администратор»; чтобы команды протокола выполнялись без изменений, ее можно переименовать в PowerShell внутри ВМ:

```
Rename-LocalUser -Name 'Администратор' -NewName 'Administrator'
```

Если учетная запись не переименована, в командах вместо Administrator указывается Администратор.

Ожидаемый результат. Вход в систему выполняется, на рабочем столе указаны редакция Windows Server 2025 Datacenter Evaluation и сборка 26100 (рисунок 2 статьи).

4.4 Подготовка стенда и контрольная точка Base

```
$c = Get-Credential Administrator
.\02-Host-DeployToVM.ps1 -Credential $c
```

Скрипт отключает образ ISO, копирует гостевой скрипт в C:\DedupExp, устанавливает компоненты FS-Data-Deduplication и Windows-Server-Backup, размечает тома E: (DATA) и G: (BACKUP), включает дедупликацию на томе E:, задает MinimumFileAgeDays = 0 и отключает все стандартные расписания дедупликации. Затем создается и оптимизируется исходный набор 40 ГБ, ВМ выключается и создается контрольная точка Base. Длительность шага определяется в основном записью и оптимизацией исходного набора.

Ожидаемый результат. Создан файл results\stand_status.txt: дедупликация тома E: включена, MinimumFileAgeDays = 0, у всех расписаний Enabled = False, на исходном наборе 40 ГБ сэкономлено около 18,7 ГБ (рисунки 3–5 статьи). Команда Get-VMSnapshot WS2025-DEDUP показывает контрольную точку Base.

4.5 Пробный прогон

```
.\03-Host-RunAll.ps1 -Credential $c -Smoke
```

Выполняется одна короткая серия (еженедельное расписание, 0,5 ГБ/сут, 7 сут, без копий WSB) с откатом к Base, примерно 10–15 мин. Пробный прогон проверяет откат, связь с ВМ, работу задачи планировщика и копирование результатов на хост; его данные в обработку не включаются.

Ожидаемый результат. В папке results_smoke\Weekly_0.5GB_r1 находятся runs.csv (одна строка, объем перед запуском около 3,5 ГБ), events.csv, meta.json, progress.log и done.txt, в конце выводится сводная таблица.

4.6 Основной прогон

```
.\03-Host-RunAll.ps1 -Credential $c -Repeats 4
```

Выполняются 16 серий (2 расписания × 2 интенсивности × 4 повтора) в случайном порядке с фиксированным зерном 2026; без параметра -Repeats план составляет 20 серий (n = 5). Каждая серия начинается с отката к Base и выполняется внутри ВМ как задача планировщика от имени SYSTEM, хост раз в минуту выводит последнюю строку журнала серии. Результаты копируются в папку results\<расписание>_<приток>GB_r<повтор> до следующего отката.

Прогон можно прервать (Ctrl+C) и запустить той же командой снова: серии с файлом done.txt пропускаются, незавершенная серия выполняется заново от контрольной точки Base. Если на хосте не хватает памяти для ВМ с 8 ГБ ОЗУ, к команде добавляется ключ -MemoryGB 4; объем памяти задается после каждого отката.

Ожидаемый результат. Папки всех серий содержат done.txt; в папке results созданы объединенные файлы runs.csv, events.csv и wsb.csv, в конце выводится сводная таблица. При ежедневном расписании объем перед запуском близок к суточному притоку (около 2 и 6 ГБ), при еженедельном – к недельному (около 14 и 42 ГБ).

Для расширенного плана (n = 8) используется ключ -Repeats 8, для контрольных серий без резервного копирования ключ -NoBackup (результаты сохраняются в отдельную папку results_noWSB). Начиная с этой версии гостевой скрипт перед каждым заданием дополнительно записывает показатели Get-DedupStatus (столбцы StatusInPolicyGB, StatusOptimizedGB, StatusUnoptGB) для сравнения с основной метрикой.

4.7 Обработка результатов

```
pip install numpy matplotlib
python analyze_results.py --results results
```

Ожидаемый результат. В папке results\analysis созданы summary.csv (сводная таблица по всем показателям, таблицы 3 и 5 статьи), summary.txt (то же в текстовом виде с результатами U-критерия), stats.txt (стратифицированный перестановочный тест, поправка Холма, величина эффекта, доверительные интервалы Ходжеса-Лемана, мощность, анализ без серий с 4 ГБ ОЗУ, проверка метрики и влияния WSB; таблица 4 статьи) и рисунки fig6_dynamics.png, fig7_prejob.png, fig8_jobtime.png (рисунки 6–8 статьи). Критерий завершения выполнен, если в каждой группе CV < 15 %, а медианы при ежедневном и еженедельном расписании различаются не менее чем на 10 %.

5. Фактические условия проведения

Эксперимент проведен на ВМ Windows Server 2025 Datacenter Evaluation (сборка 26100), размещенной на диске F: хоста. Стенд подготовлен 26.09.2026, серии выполнены с 27.09 по 03.10.2026, суммарное машинное время прогона составило 139 ч. Прогон несколько раз прерывался (ошибки подключения к ВМ, нехватка места на диске и оперативной памяти хоста) и продолжался повторным запуском 03-Host-RunAll.ps1; прерванные серии выполнялись заново от контрольной точки Base.

Отклонения от плана:

1) Из-за длительности прогона выполнено 16 серий из 20 запланированных, по 4 повтора на каждую комбинацию факторов. Прогон начат по плану из 20 серий и остановлен после 13-й серии; недостающие повторы для ежедневного расписания (Daily_2GB_r3, Daily_2GB_r4, Daily_6GB_r2) выполнены отдельными запусками 03-Host-RunAll.ps1 с планом, ограниченным параметрами -Schedules, -Intensities и -Repeats (готовые серии при этом пропускаются), например:

```
.\03-Host-RunAll.ps1 -Credential $c -Schedules Daily -Intensities 2 `
    -Repeats 4 -MemoryGB 4
```

Поэтому номера повторов в комбинациях не совпадают (таблица 4). На результат это не влияет: все серии начинаются с одной контрольной точки, а порядок серий случайный.

2) Серии Daily_2GB_r3, Daily_2GB_r4 и Daily_6GB_r2 выполнены с 4 ГБ ОЗУ ВМ (ключ -MemoryGB 4) из-за нехватки памяти на хосте. На объем неоптимизированных данных это не влияет, но могло увеличить разброс длительности заданий оптимизации.

Таблица 4 – Выполненные серии

Комбинация	**Серии**	**ОЗУ ВМ**
2 ГБ/сут, ежедневно	Daily_2GB_r1, r2, r3, r4	r1, r2 – 8 ГБ; r3, r4 – 4 ГБ
2 ГБ/сут, еженедельно	Weekly_2GB_r2, r3, r4, r5	8 ГБ
6 ГБ/сут, ежедневно	Daily_6GB_r1, r2, r4, r5	r2 – 4 ГБ; остальные – 8 ГБ
6 ГБ/сут, еженедельно	Weekly_6GB_r1, r2, r3, r4	8 ГБ

Основные результаты приведены в таблице 5, полностью – в таблицах 3–5 статьи.

Таблица 5 – Средний объем неоптимизированных данных перед запуском задания, ГБ (n = 4)

Приток	**Ежедневно: медиана [IQR]**	**Еженедельно: медиана [IQR]**	**CV, % (ежедн. / еженед.)**	**U; p (по Холму)**
2 ГБ/сут	1,97 [0,03]	14,31 [0,59]	2,6 / 4,0	0; 0,029 (0,057)
6 ГБ/сут	5,98 [0,26]	42,00 [0,77]	3,3 / 2,3	0; 0,029 (0,057)

Переход к еженедельному расписанию увеличил медиану в 7,25 раза при 2 ГБ/сут и в 7,02 раза при 6 ГБ/сут. Коэффициент вариации во всех группах не превышает 4,0 %, критерий завершения выполнен. Основная проверка (стратифицированный перестановочный тест по обеим интенсивностям) дает p = 0,0004; без серий с 4 ГБ ОЗУ p = 0,004. Отдельные сравнения после поправки Холма при n = 4 не значимы, поэтому выводы предварительные.

6. Формат файлов результатов

CSV-файлы записываются в кодировке UTF-8, разделитель полей – точка с запятой, десятичный разделитель – точка. Day – номер модельных суток от начала серии; задание в сутки Day выполняется в 02:00, до притока этих суток. Состав файлов в папке каждой серии приведен в таблице 6.

Таблица 6 – Файлы результатов серии

Файл	Содержимое
runs.csv	Строка на каждый запуск задания: Schedule, IntensityGB, Repeat, Run, Day, Timestamp, UnoptimizedGB (объем перед запуском), LogicalGB, JobMinutes, ResidualGB (остаток после задания), SavedGB, JobResult
events.csv	Состояние тома по модельным часам: Schedule, IntensityGB, Repeat, Day, Hour, Event (start, intake, job), UnoptimizedGB, LogicalGB, SavedGB
wsb.csv	Полные копии WSB: Schedule, IntensityGB, Repeat, Day, UsedGB, ImageGB, Minutes, ExitCode
meta.json	Параметры серии и стенда: ОС и сборка, vCPU, RamGB, размер тома, UsageType, MinimumFileAgeDays, объем и экономия исходного набора, время начала
progress.log	Журнал выполнения серии
done.txt, failed.txt	Признак успешного завершения серии или ошибки (в failed.txt записан текст ошибки)

Кроме папок серий, в каталоге results находятся stand_status.txt (сведения о стенде после подготовки), plan_order.csv (порядок серий последнего запуска) и объединенные runs.csv, events.csv, wsb.csv.

7. Возможные неполадки

Таблица 7 – Возможные неполадки и их устранение

Признак	Причина и действие
«ВМ WS2025-DEDUP уже существует» при запуске 01-Host-CreateVM.ps1	ВМ осталась от прошлой попытки. Запустить скрипт с ключом -Replace.
ВМ не загружается с DVD, выполняется попытка загрузки по сети	Клавиша не нажата вовремя. Выключить ВМ, запустить снова и сразу нажать любую клавишу в окне подключения.
«Недопустимые учетные данные» при подключении к ВМ	Неверное имя или пароль. Проверить имя учетной записи (Administrator или Администратор, п. 4.3) и раскладку клавиатуры при вводе пароля. Сразу после загрузки ВМ ошибка может появляться временно, скрипты ожидают до 4 мин.
«Не удалось выделить … МБ ОЗУ» при запуске ВМ	На хосте недостаточно свободной памяти. Закрыть лишние программы или запустить 03-Host-RunAll.ps1 с ключом -MemoryGB 4.
«На диске F: свободно … ГБ, для серии нужно не меньше 180 ГБ» или ВМ в состоянии «Приостановлена»	На диске хоста не хватает места. Освободить место на диске F:. В первом случае запустить скрипт снова (готовые серии будут пропущены), во втором – выполнить Resume-VM WS2025-DEDUP, скрипт продолжит ожидание серии.
Серия завершилась с ошибкой (создан failed.txt)	Причина указана в progress.log и failed.txt в папке серии. После ее устранения запустить 03-Host-RunAll.ps1 снова.

Приложение А

Ручная проверка настроек и измерения

Проверка выполняется внутри ВМ в окне подключения или в сеансе Enter-PSSession -VMName WS2025-DEDUP -Credential $c:

```
Get-DedupVolume -Volume E: |
    Format-List Volume, Enabled, UsageType, MinimumFileAgeDays
Get-DedupSchedule | Format-Table Name, Type, Enabled
Update-DedupStatus -Volume E:
Get-DedupStatus -Volume E: |
    Format-List OptimizedFilesCount, InPolicyFilesCount, SavedSpace

# объем неоптимизированных данных (так же считает Measure-Fast)
$u = Get-ChildItem E:\Data -Recurse -File |
  Where-Object { $_.Length -ge 32KB -and
    -not ($_.Attributes -band [IO.FileAttributes]::ReparsePoint) } |
  Measure-Object Length -Sum
'{0:N2} ГБ' -f ($u.Sum / 1GB)

# у оптимизированного файла есть точка повторного анализа
fsutil reparsepoint query E:\Data\base\f00000.bin
```

После запуска задания оптимизации (Start-DedupJob -Volume E: -Type Optimization -Wait) значение $u уменьшается практически до нуля, а fsutil для оптимизированных файлов показывает тег точки повторного анализа дедупликации 0x80000013. Файлы меньше 32 КБ не оптимизируются и в расчет не входят.

Приложение Б

Режим реального времени

Для проверки на настоящем расписании гостевой скрипт создает задание дедупликации через New-DedupSchedule и задачи планировщика. Команды выполняются внутри ВМ после отката к контрольной точке Base:

```
cd C:\DedupExp
.\Dedup-ScheduleExperiment.ps1 -Action RealTimeSetup `
    -Schedule Weekly -IntensityGB 2
```

Создаются расписание дедупликации Exp-Weekly (воскресенье 02:00, не более 6 ч; при -Schedule Daily – ежедневно в 02:00) и задачи планировщика:

1) DedupExp-Intake – приток каждый час с 08:00 до 19:00 (12 порций в сутки);

2) DedupExp-Measure – замер объема в 01:55, перед запуском задания, с записью в runs.csv;

3) DedupExp-Backup – полная копия тома E: средствами WSB в субботу в 23:00.

Результаты записываются в C:\DedupExp\out. Два недельных цикла в этом режиме занимают 14 календарных суток на одну серию, поэтому результаты статьи получены в ускоренном режиме. Удаление расписания и задач:

```
Get-ScheduledTask -TaskName 'DedupExp-*' |
    Unregister-ScheduledTask -Confirm:$false
Remove-DedupSchedule -Name 'Exp-Weekly'
```